Documents de spécifications (encoding vectors)

RENDU Étape intermédiaire — Adam, Ayman, Tom

Installation

Action	Commande
Cloner le projet	`git clone git@github.com:yahia-adam/deepRL_5iabd.git && cd`
Installer les dépendances	`uv sync`
Activer l'environnement	`source .venv/bin/activate`
Lancer un script	`uv run python -m mypythonlib.envs.quarto`

1 Line World

1.1 Jeu avec joueur humain + GUI

```
PYTHONPATH=. uv run python3 -m deeprl_5iabd.envs.line_world
```

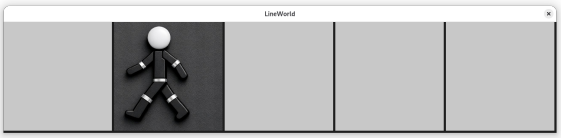

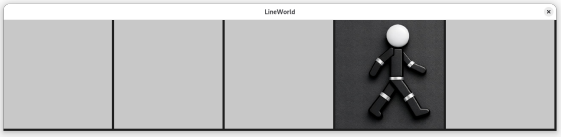

1.2 Proposition de description de l'état du jeu (vecteur d'encoding)

Vecteur de **1 valeur** : la position de l'agent. Un vecteur est utilisé afin que tous les environnements partagent les mêmes méthodes avec les mêmes signatures (classe parente `BaseEnv`).

```python
def get_observation_space(self) -> list[int]:
    return [self.agent_pos]
```

1.3 Proposition de description d'une action du jeu (vecteur d'encoding)

Vecteur de **2 valeurs** `[gauche, droite]` :

- `[0, 1]` quand l'agent est à la case 0
- `[1, 1]` quand l'agent est entre la case 1 et la case 3
- `[1, 0]` quand l'agent est à la case 4

```python
def get_action_space(self) -> list[int]:
    """0: gauche, 1: droite"""
    action = [1, 1]
    if self.agent_pos == 0:
        action[0] = 0
    if self.agent_pos == 4:
        action[1] = 0
    return action
```

2 Grid World

2.1 Jeu avec joueur humain + GUI

```
PYTHONPATH=. uv run python3 -m deeprl_5iabd.envs.grid_world
```

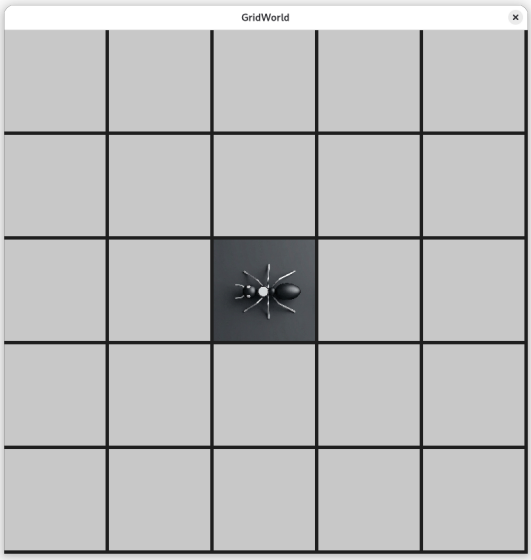

2.2 Proposition de description de l'état du jeu (vecteur d'encoding)

Vecteur de **25 valeurs** représentant le plateau 5×5, rempli de -1 partout sauf à la position de l'agent où la valeur est 1.

```python
def get_observation_space(self):
    return self.board.flatten().tolist()
```

2.3 Proposition de description d'une action du jeu (vecteur d'encoding)

Vecteur de **4 valeurs** `[bas, haut, droite, gauche]`, chaque valeur vaut `1` si l'action est disponible, `0` sinon.

Exemples :

- `[1, 0, 1, 0]` quand l'agent est en haut à gauche (case $(0, 0)$)
- `[1, 1, 1, 1]` quand l'agent est au centre (case $(2, 2)$)

```python
def get_action_space(self) -> list[int]:
    picks = np.ones(4)
    if self.agent_pos[0] == 0:
        picks[1] = 0
    if self.agent_pos[1] == 0:
        picks[3] = 0
    if self.agent_pos[0] == self.BOARD_SIZE - 1:
        picks[0] = 0
    if self.agent_pos[1] == self.BOARD_SIZE - 1:
        picks[2] = 0
    return picks.tolist()
```

3 Tic-Tac-Toe

3.1 Jeu avec joueur humain + GUI

```
PYTHONPATH=. uv run python3 -m deeprl_5iabd.envs.tictactoe
```

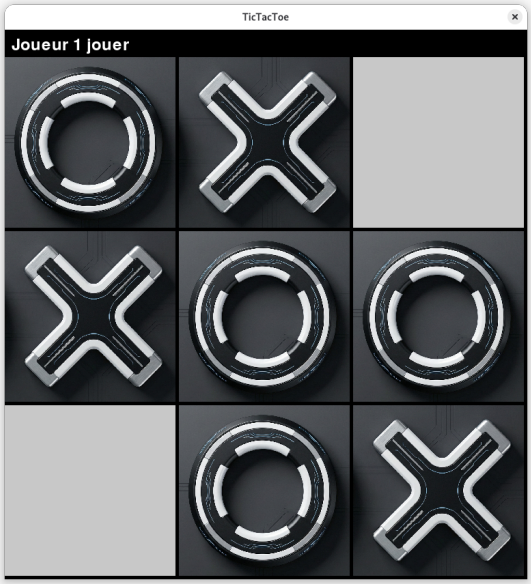

3.2 Proposition de description de l'état du jeu (vecteur d'encoding)

Vecteur de **9 valeurs** représentant le plateau 3×3 :
- -1 quand la case est vide
- 0 quand la case est occupée par le joueur O (joueur 0)
- 1 quand la case est occupée par le joueur X (joueur 1)

```python
def get_observation_space(self) -> np.ndarray:
    return self.board.flatten().tolist()
```

3.3 Proposition de description d'une action du jeu (vecteur d'encoding)

Vecteur de **9 valeurs**, une par case du plateau :
- 1 quand la case est **vide** (action jouable)
- 0 quand la case est **occupée** (action non disponible)

```python
def get_action_space(self):
    return (self.board.flatten() == -1).astype(int)
```

4 Quarto

4.1 Jeu avec joueur humain + GUI

```
PYTHONPATH=. uv run python3 -m deeprl_5iabd.envs.quarto
```

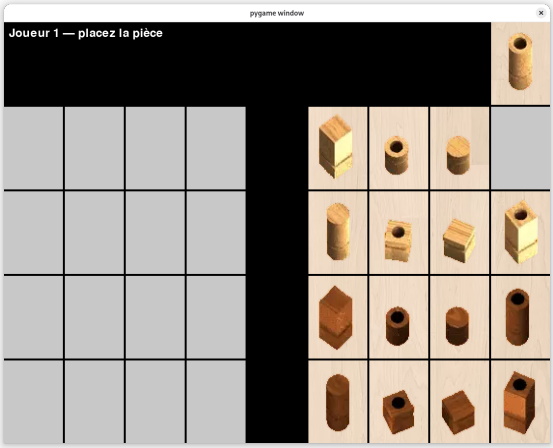

4.2 Proposition de description de l'état du jeu (vecteur d'encoding)

Vecteur de **132 valeurs** :

Index	Contenu
`[0:4]`	Pièce actuellement sélectionnée (4 attributs), ou $[-1, -1, -1, -1]$ si aucune
`[4:68]`	Plateau 4×4 (16 cases $\times$ 4 valeurs) : -1 si vide, sinon les 4 attributs
`[68:132]`	Pièces restantes (16 pièces $\times$ 4 valeurs) : -1 si déjà jouée, sinon ses 4 attributs

```python
def get_observation_space(self) -> list[int]:
    return (self.selected.tolist()
            + self.board.flatten().tolist()
            + self.available.flatten().tolist())
```

4.3 Proposition de description d'une action du jeu (vecteur d'encoding)

Vecteur de **32 valeurs** :

Index	Contenu
`[0:16]`	**Choisir une pièce** : `1` si la pièce est disponible, `0` sinon
`[16:32]`	**Placer une pièce** : `1` si la case est vide, `0` sinon

Selon la phase de jeu, une moitié du vecteur est automatiquement à `0` :

- Phase **sélection** (`selecting=True`) : `[16:32]` vaut tout `0` (pas de placement possible)
- Phase **placement** (`selecting=False`) : `[0:16]` vaut tout `0` (pas de choix de pièce possible)

```python
def get_action_space(self) -> list[int]:
    """0-15: choisir piece, 16-31: placer piece"""
    empty = [0] * self.NUM_PIECES

    if self.selecting:
        picks = [0 if self.available[r, c, 0] == -1 else 1
                 for r in range(4) for c in range(4)]
        return picks + empty
    else:
        picks = [1 if self.board[r, c, 0] == -1 else 0
                 for r in range(4) for c in range(4)]
        return empty + picks
```

5 Simulation de jeu avec joueur aléatoire

```
PYTHONPATH=. uv run python3 -m deeprl_5iabd.training.
   envs_per_counter
```

On teste 1 000 000 parties jouées par un agent aléatoire sur chaque environnement.

- **LineWorld / GridWorld** : ∼15–20M parties/sec.
- **TicTacToe** : ∼26K parties/sec.

— **Quarto** : ∼38K parties/sec, légèrement plus rapide que TicTacToe (raison inconnue).

```
┌(~/Documents/esgi/drl/deepRL_5iabd)──────────────────────────────────────────────────────────────
└(00:24:14 on main ● ⋆)──> PYTHONPAH=. uv run python3 -m deeprl_5iabd.training.envs_per_counter
pygame 2.6.1 (SDL 2.28.4, Python 3.12.12)
Hello from the pygame community. https://www.pygame.org/contribute.html


TEST SUR 1000000 PARTIES ...
-------------------------------------------
Environnement         Durée (s)   Matchs/sec
-------------------------------------------
line_world                 0.05     19697311
GridWorld                  0.07     15143620
TicTacToe                 38.35        26074
quarto                    25.98        38493
┌(~/Documents/esgi/drl/deepRL_5iabd)──────────────────────────────────────────────────────────────
└(00:27:22 on main ● ⋆)──> 
```

```python
def count_n_match_time(env: BaseEnv, num_episode):
    player = RandomPlayer(action_dim=len(env.get_action_space()))
    s = perf_counter()

    i = 0
    while (i <= num_episode):
        while (not env.is_game_over()):
            action_spaces = env.get_action_space()
            probs = player.forward(x=None, mask=action_spaces)
            probs_dist = Categorical(probs)
            action_pos = probs_dist.sample()
            env.step(action_pos.item())
        i += 1
    e = perf_counter()

    total_time = e - s
    match_per_s = num_episode / total_time
    return total_time, match_per_s
```